

MoodMetrics — Rapport d'évaluation


Généré le 09/07/2026 à 18:27

1. Introduction

MoodMetrics est une API d'analyse de sentiments qui attribue à chaque tweet un score compris entre -1 et 1. Elle repose sur **deux classifieurs indépendants** — une régression logistique pour le sentiment positif, une autre pour le sentiment négatif — entraînés sur une vectorisation TF-IDF (uni- et bigrammes).

Ce rapport évalue ces deux classifieurs. Les tweets annotés sont chargés depuis la table *tweets* (MySQL), puis répartis par un **split stratifié 80/20** (`random_state = 42`) afin de garantir la reproductibilité et de préserver la proportion des classes. Chaque classifieur est réentraîné sur la partie « entraînement » puis évalué sur la partie « test » jamais vue. Les métriques (matrice de confusion, précision, rappel, F1-score) sont calculées avec scikit-learn. Le corpus rassemble **1066 tweets annotés** (425 positifs, 428 négatifs, 213 neutres). Le jeu de données est suffisamment volumineux pour une évaluation crédible.


2. Matrice de confusion — sentiment positif



Lignes = valeur réelle, colonnes = prédiction du modèle.

Dans cette matrice, la classe « présent » désigne un tweet réellement positif. On lit : **82 vrais positifs (VP)** — des tweets positifs correctement détectés ; **128 vrais négatifs (VN)** — des tweets non positifs correctement écartés ; **1 faux positif (FP)** — des tweets non positifs annoncés à tort comme positifs (fausses alertes) ; et **3 faux négatifs (FN)** — des tweets positifs manqués par le modèle. Les erreurs penchent vers les oublis (3 FN contre 1 FP) : le classifieur est **prudent** et laisse passer des tweets positifs, ce qui privilégie la précision au détriment du rappel.

3. Matrice de confusion — sentiment négatif



Lignes = valeur réelle, colonnes = prédiction du modèle.

Dans cette matrice, la classe « présent » désigne un tweet réellement négatif. On lit : **81 vrais positifs (VP)** — des tweets négatifs correctement détectés ; **127 vrais négatifs (VN)** — des tweets non négatifs correctement écartés ; **1 faux positif (FP)** — des tweets non négatifs annoncés à tort comme négatifs (fausses alertes) ; et **5 faux négatifs (FN)** — des tweets négatifs manqués par le modèle. Les erreurs penchent vers les oublis (5 FN contre 1 FP) : le classifieur est **prudent** et laisse passer des tweets négatifs, ce qui privilégie la précision au détriment du rappel.

4. Mesures de performance

Le tableau ci-dessous détaille la précision, le rappel et le F1-score pour chaque classe (« présent » = le sentiment est bien celui du classifieur, « absent » = il ne l'est pas) et pour chacun des deux classifieurs.

Classifieur	Classe	Précision	Rappel	F1-score	Support
Sentiment positif	présent	0.99	0.96	0.98	85
	absent	0.98	0.99	0.98	129
Sentiment négatif	présent	0.99	0.94	0.96	86
	absent	0.96	0.99	0.98	128

Le classifieur **sentiment positif** affiche une précision (99%) supérieure au rappel (96%) : ses annonces « positif » sont fiables mais il en manque quelques-uns (F1 = 98%). Le classifieur **sentiment négatif** affiche une précision (99%) supérieure au rappel (94%) : ses annonces « négatif » sont fiables mais il en manque quelques-uns (F1 = 96%).

Rappel des définitions : la **précision** mesure la part d'annonces correctes parmi les tweets prédits dans une classe ; le **rappel** mesure la part de tweets d'une classe effectivement retrouvés ; le **F1-score** en est la moyenne harmonique.

5. Analyse des performances

Forces. Le meilleur classifieur est **sentiment positif** (F1 = 98%, précision = 99%, rappel = 96%). Les deux modèles dépassent nettement le hasard, ce qui confirme que la représentation TF-IDF combinée à une régression logistique capte un signal lexical exploitable pour séparer les tweets.

Faiblesses. Le classifieur **sentiment négatif** est le plus fragile (F1 = 96%), avec le rappel comme point faible (94%). Ce déséquilibre traduit un compromis précision/rappel encore perfectible, typiquement sur les tweets courts, ironiques ou ambigus dont le vocabulaire ne porte pas clairement le sentiment.

Biais éventuels. En examinant le sens des erreurs, le modèle positif **sous-prédit** sa classe (3 FN > 1 FP), et le modèle négatif **sous-prédit** sa classe (5 FN > 1 FP). Par ailleurs, le corpus contient 213 tweets neutres (ni positifs ni négatifs) : chaque classifieur voit donc une classe « présent » minoritaire, ce qui l'expose à un biais en faveur de la classe « absent ». L'usage de `class_weight="balanced"` à l'entraînement atténue ce biais sans totalement le supprimer.

6. Recommandations

- **Enrichir les données annotées** : augmenter le volume et la diversité des tweets (registres, thématiques, tweets neutres et ambigus) pour réduire la variance des métriques et fiabiliser l'évaluation.
- **Rééquilibrer les classes** : compléter la classe minoritaire, ou combiner sur-échantillonnage et `class_weight` pour limiter le biais vers la classe « absent ».
- **Améliorer la représentation du texte** : étendre les n-grammes TF-IDF, ajuster `min_df/max_df`, et tester des sous-mots pour mieux gérer les fautes et le vocabulaire des réseaux sociaux.
- **Renforcer le prétraitement** : normaliser la casse, les emojis, les hashtags et la négation, qui inverse le sentiment et piège souvent les modèles linéaires.

- **Régulariser et calibrer** : explorer le paramètre C de la régression logistique par validation croisée et calibrer les probabilités pour un score plus fiable.
- **Comparer d'autres modèles** : évaluer un SVM linéaire ou un modèle de langage pré-entraîné (type transformeur) afin de mieux traiter l'ironie et le contexte.